Atenção simplicial relacional (rota estática de texto-relação)

Pré-treino zero-shot em tabelas relacionais onde a **agregação de vizinhança é condicionada ao tipo da chave estrangeira**, e cada tipo de relação é representado pelo **embedding de texto da sua descrição de schema** (ex.: `"director between movie and person"`).

O principal resultado empírico desta branch é um novo recorde de **309 segundos (5m09s)** até o alvo fixo de AUROC pooled `0.81621`, contra 7m26s do recorde anterior. A receita mantém o stream de relações estático entre blocos (`update_relations=False`), usa warmup longo do Muon e verifica o primeiro checkpoint pós-update elegível no step 100.

Uma auditoria mediu AUROC pooled `0.8651` no step 0. Esse diagnóstico roda fora do timer e não pode criar recorde nem selecionar checkpoint. “Estático” descreve o estado de relação dentro do forward; o encoder de relações e a atenção de vizinhança continuam treináveis.

---

1. A ideia em uma linha

A atenção de vizinhança convencional pergunta "*quão relevante é o filho* `s` *para o pai* `q`*?*". Aqui o score também depende de **qual relação** os conecta:

```
score(q, s, r) = Σ_d  q_d · k^cell_s,d · k^rel_r,d          (por head)
value(s, r)    = v^cell_s ⊙ v^rel_r                          (gate estilo FiLM)
```

`r` é um embedding por tipo de relação, inicializado a partir de texto e — na rota vencedora — **não atualizado iterativamente** entre os blocos.

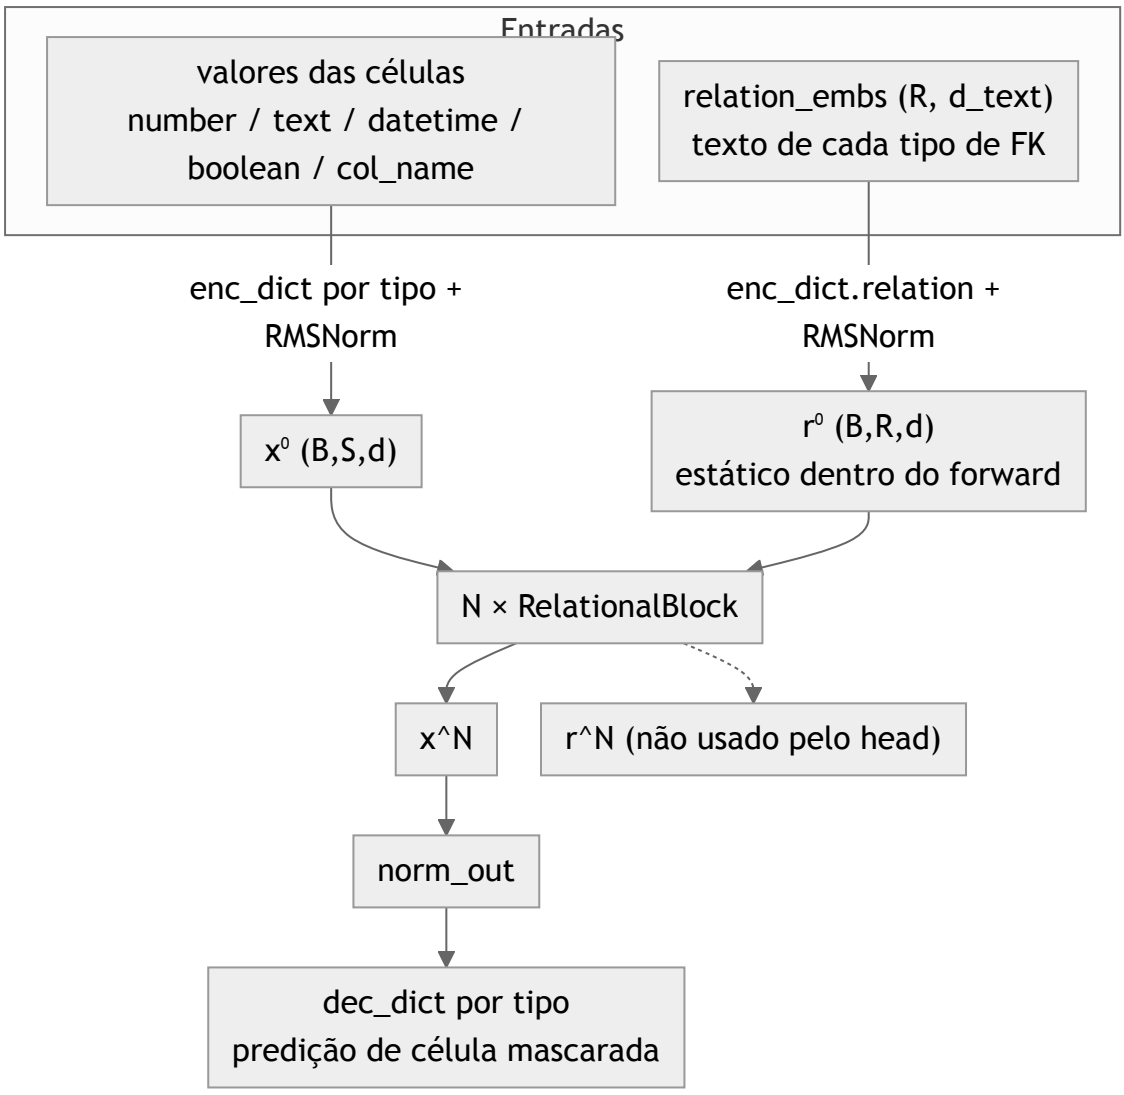
> Nota (ver `project_simplicial_diagnosis`): algebricamente isto é um operador DistMult/FiLM de rank 1, não um 2-simplex de verdade — `r` está colado à aresta e a softmax é segmentada apenas por `q`. O nome "simplicial" é histórico.

---

2. Dois streams

O modelo carrega dois streams de tokens através de cada bloco:

- `x` **— células** `(B, S, d)`: um token por célula (linha, coluna) no subgrafo amostrado.
- `r` **— relações** `(B, R, d)`: um token por *tipo* de chave estrangeira, compartilhado por todas as arestas que o instanciam.

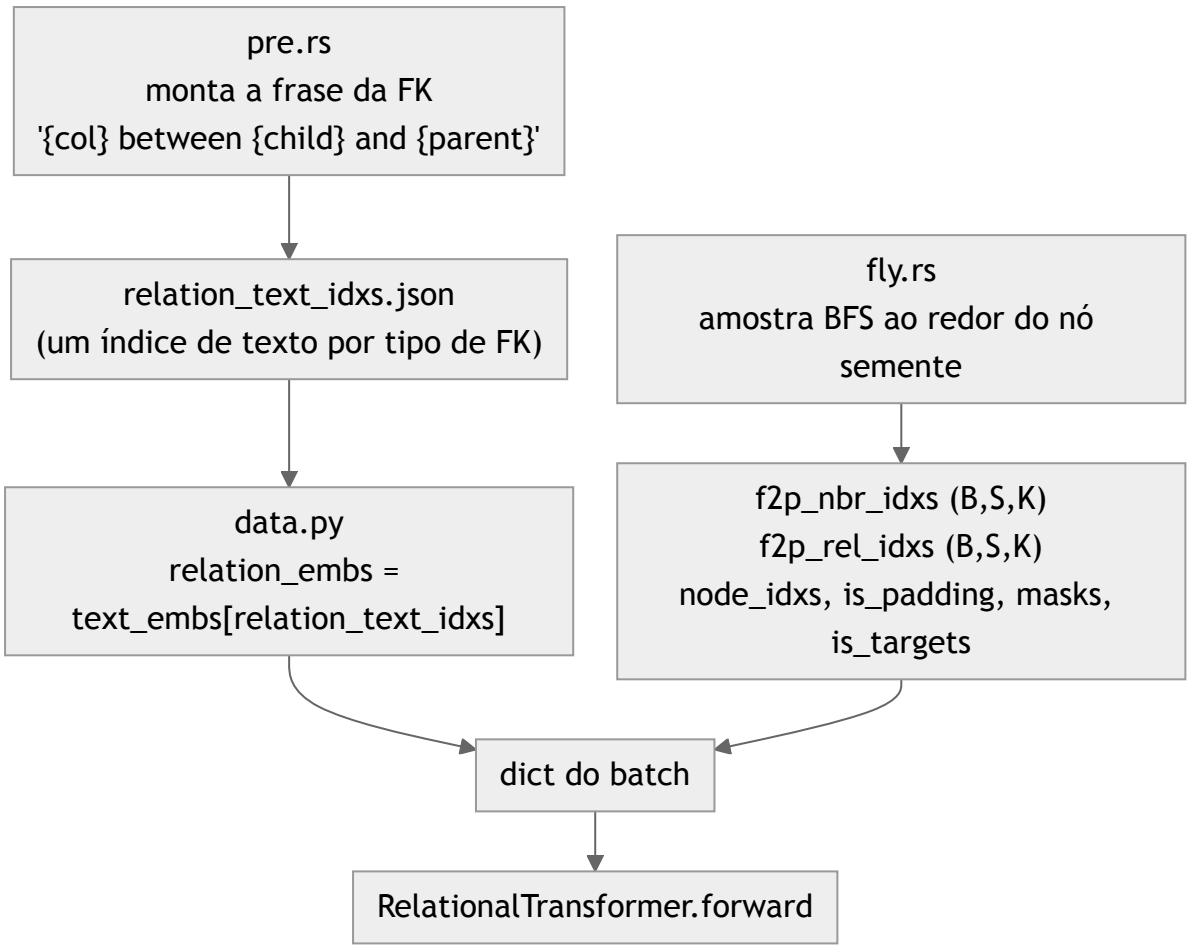


Só `x` chega ao head de predição; `r` condiciona `x` mas nunca é decodificado.

---

3. Pipeline de dados (amostragem à prova de vazamento)

A extensão em Rust (`rustler/`) constrói o texto da relação e amostra um subgrafo temporal e livre de vazamento por nó semente.

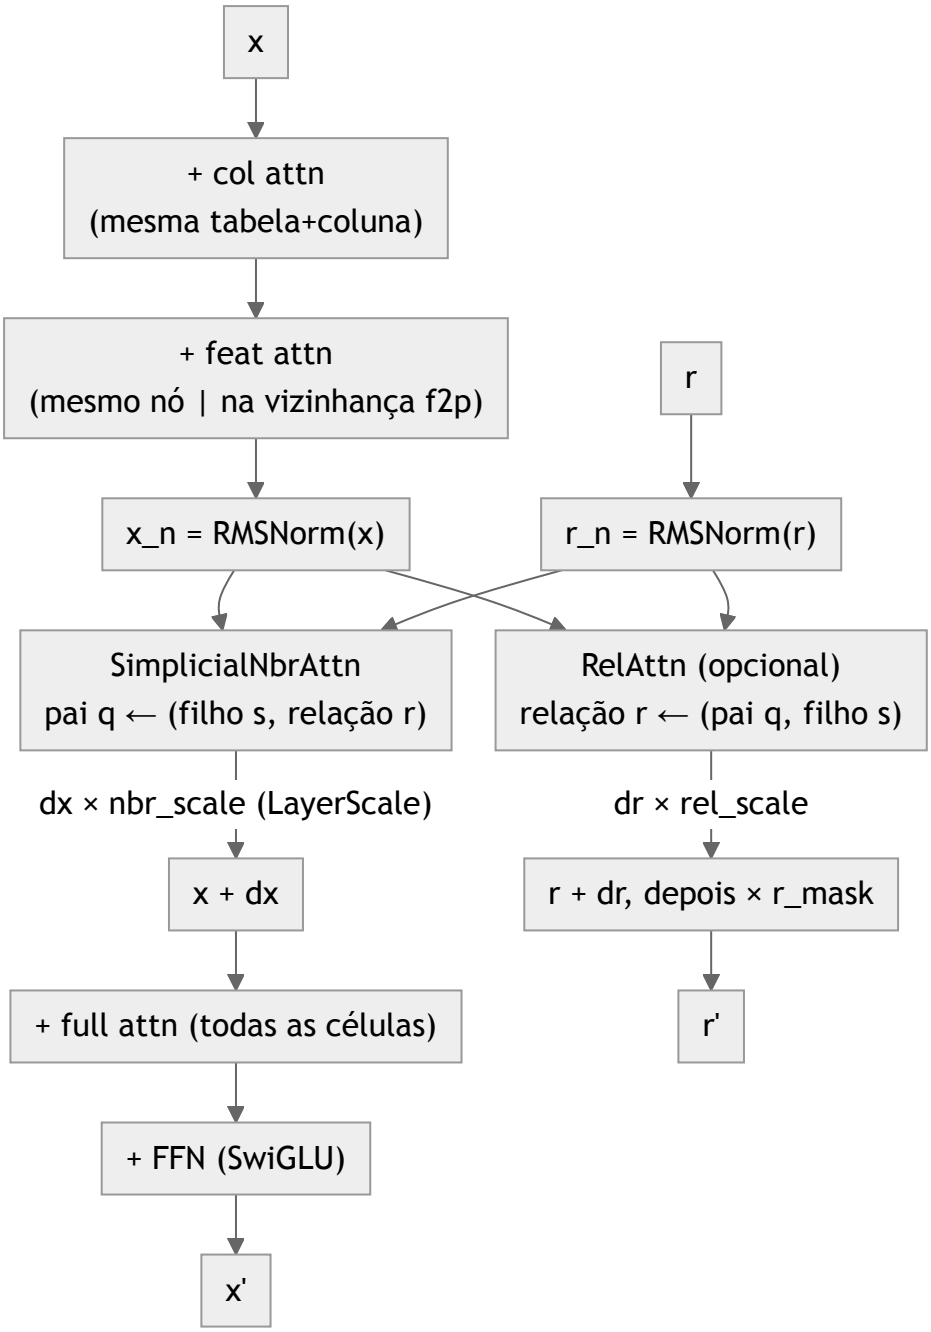


Prevenção de vazamento no `fly.rs` (validada):

vetor	mecanismo	ref
temporal	arestas com `timestamp > seed_node.timestamp` são descartadas	`fly.rs:447`
valor do alvo	a célula alvo recebe `is_target` + `masks=True`; o modelo usa `mask_emb` na entrada e o valor só como rótulo	`fly.rs:528–532`
colunas vazantes	`columns_to_drop` são removidas do nó semente **e** dos nós de mesmo timestamp	`fly.rs:482–483`
holdout	`train_tasks` exclui `holdout_db`; a validação carrega só o artefato do holdout → zero-shot	`nanort_train.py:79–82`

---

4. Dentro de um `RelationalBlock`



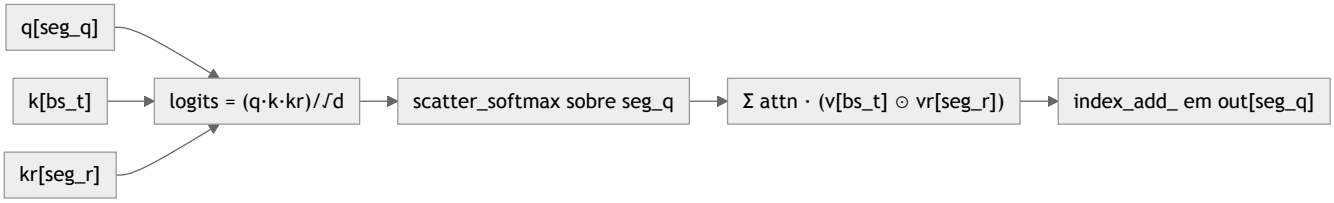
- `col` / `feat` / `full` são atenções mascaradas padrão (`flex_attention`).
- `SimplicialNbrAttn` atualiza células; `RelAttn` atualiza relações.
- **`update_relations=False`** remove o `RelAttn` inteiro → `r` permanece r^0 entre os blocos. Esta é a configuração vencedora; gradientes ainda chegam ao encoder de relações e ao caminho de atenção de vizinhança.
- `nbr_scale` / `rel_scale` são gates LayerScale por canal sobre os deltas (`simplicial_layerscale_init` , default 1.0 = residual simples).
- O stream de relações é re-mascarado com `r_mask` depois de cada bloco (defensivo; o encoder de relação tem bias).

5. Edge-scatter esparso (por que caber na memória)

Logits densos `(B, H, S, S, K)` explodiriam. `build_rel_batch` compila os slots de FK válidos em triplas de arestas achatadas, uma vez por batch:

```
seg_q = b·S + q   (célula pai)      → queries; segmenta a softmax e espalha a saída
bs_t  = b·S + s   (célula filho)    → keys/values
seg_r = b·R + r   (tipo de relação) → K/V da relação; segmenta o RelAttn
```

O `SimplicialNbrAttn` então faz, sobre as `T` arestas (tudo `index_select` / `index_add_`, para o tráfego de índices ficar em 1-D):



RMSNorm por head (`qk_norm`) é aplicado a `q`, `k` e `kr` antes do produto trilinear, para a escala do logit trilinear não colapsar a entropia da softmax.

---

6. SIGReg (regularização geométrica)

O `SIGReg` regulariza o estado oculto por célula depois do bloco `sigreg_layer` (visões de linha/coluna derivadas de `node_idxs` e da chave (tabela, coluna)). Loss auxiliar apenas em treino: `(1−λ_row−λ_col)·L_sup + λ_row·row + λ_col·col`, treinada por um AdamW fp32 separado. O recorde usa a visão global de coluna depois do bloco 0 com `λ_col=1e−3`; `sigreg_layer=None` e lambdas zero desativam o módulo nas ablations.

---

7. Receita de treino (o resultado)

ingrediente	valor	por quê
stream de relações	**estático** (`update_relations=False`)	o `RelAttn` dinâmico corrompia o prior de texto (one-hot, norma de `r` ×4)
simplicial	todos os blocos	condiciona a agregação de vizinhança ao prior de texto limpo
optimizer	Muon (pesos 2-D) + AdamW (o resto)	
warmup do muon	**3000 steps**	sustenta o init forte; o modelo se afasta dele mesmo com LR minúsculo
SIGReg	bloco 0, visão global de coluna, `λ_col=1e−3`	regulariza a geometria da representação inicial
eval oficial	step 100 (`eval_at_step1=False`)	primeiro crossing pós-update elegível no recorde
eval diagnóstico	step 0	fora do timer; não cria recorde/checkpoint
checkpoint	melhor AUROC pooled pós-update elegível	o step 0 é excluído explicitamente

Métrica: `time_to_target` = segundos de wall-clock histórico até o AUROC pooled (`val/auroc_pooled`, alias legado `val/auroc_zero_shot`) cruzar **0.81621** pela primeira vez no banco de holdout. O timer inclui as avaliações agendadas depois que começa; não é apenas tempo de kernel ou optimizer.

---

8. Resumo do diagnóstico

- A arquitetura inicializada completa já tem sinal zero-shot forte: pooled `0.8651` e média por tarefa `0.5682` na run auditada. Qual canal de entrada causa esse sinal precisa ser isolado por ablation; uma única run não permite atribuí-lo.
- O pooled é fortemente influenciado pelo alinhamento entre tarefas. AUROC por tarefa e a decomposição exata within/cross são diagnósticos obrigatórios, sem alterar a métrica oficial histórica.
- LR baixo / warmup longo preservam a solução inicial até a verificação elegível; ganhos pós-init devem ser reportados separadamente.
- O operador atual é uma interação trilinear fatorada/FiLM sobre arestas FK tipadas, não um complexo simplicial explícito. Um operador de ordem 2 genuíno (segundo endpoint livre + softmax conjunta) é direção de pesquisa aberta.